

Dokumentacja Specyfikacji Wymagań (SRS)

Projekt: Analiza częstości słów i analiza sentymentu w anglojęzycznych wierszach i innych utworach literackich

Wersja dokumentu: 1.0

Data: 07.06.2026

Autorzy: Jakub Rutkowski, Mikołaj Wojtkowski, Marek Grajewski

1. Wprowadzenie

Niniejszy dokument opisuje specyfikację wymagań dla skryptu R, który przeprowadza analizę częstości słów oraz analizę sentymentu tekstów literackich – wierszy i innych utworów pogrupowanych według gatunku literackiego. Dane źródłowe pochodzą z pliku PoemDataset.csv, zawierającego teksty przypisane do różnych gatunków.

System umożliwia wczytanie zbioru tekstów z pliku CSV, oczyszczenie i tokenizację, a następnie przeprowadzenie analizy częstości słów z zastosowaniem stemmingu i stem completion. Dodatkowo skrypt wykonuje analizę sentymentu przy użyciu czterech słowników: AFINN, Bing, NRC i Loughran, prezentując wyniki w formie chmur słów, tabel i wykresów wizualnych.

2. Cele systemu

- Wczytanie danych tekstowych z pliku CSV (PoemDataset.csv) z obsługą kodowania UTF-8
- Oczyszczanie tekstu: tokenizacja, usuwanie stopwords, obsługa apostrofów i znaków specjalnych, usuwanie cyfr i interpunkcji
- Przeprowadzenie stemmingu oraz stem completion w celu odzyskania pełnych form słów
- Analiza częstości słów i generowanie chmur słów dla poszczególnych gatunków
- Analiza sentymentu przy użyciu słowników w plikach CSV: AFINN, Bing, NRC, Loughran
- Wizualizacja wyników analizy sentymentu w postaci wykresów słupkowych
- Generowanie tabel z najczęściej występującymi słowami dla każdego gatunku
- Porównanie sentymentu między gatunkami literackimi przy użyciu słownika AFINN

3. Wymagania funkcjonalne

3.1. Wczytywanie danych

- Skrypt powinien umożliwić wczytanie danych tekstowych z lokalnego pliku CSV (PoemDataset.csv)
- Skrypt powinien obsługiwać kodowanie UTF-8
- Skrypt powinien automatycznie pobierać unikalne gatunki literackie z kolumny Genre
- Skrypt powinien dzielić zbiór tekstów na podzbiory odpowiadające poszczególnym gatunkom

- Skrypt powinien umożliwić wczytanie słowników sentymentu z lokalnych plików CSV: `afinn.csv`, `bing.csv`, `nrc.csv`, `loughran.csv`

3.2. Przetwarzanie i oczyszczanie danych

- Skrypt powinien zamieniać wszystkie warianty apostrofów na standardowy apostrof
- Skrypt powinien zamieniać tekst na małe litery
- Skrypt powinien usuwać cyfry z tekstu
- Skrypt powinien dzielić tekst na pojedyncze tokeny (słowa) wg spacji
- Skrypt powinien usuwać puste elementy po tokenizacji
- Skrypt powinien usuwać interpunkcję z tokenów
- Skrypt powinien usuwać stopwords z pakietu `tidytext` i `tm`
- Skrypt powinien wykonywać stemming
- Skrypt powinien zapisywać oryginalne (przed stemmingiem) słowa w globalnym słowniku do późniejszego stem completion
- Skrypt powinien wykonywać stem completion przy użyciu funkcji `stemCompletion()` z zastosowaniem trybu "prevalent"
- W przypadku braku dopasowania stem completion, skrypt powinien zachować oryginalny rdzeń słowa

3.3. Analiza częstości

- Skrypt powinien zliczać liczbę wystąpień słów (po stemmingu i completion) dla każdego gatunku
- Skrypt powinien sortować słowa według częstości (malejąco)
- Skrypt powinien generować chmurę słów dla każdego gatunku
- Skrypt powinien wyświetlać tabelę 10 najczęściej występujących słów dla każdego gatunku

3.4. Analiza sentymentu

- Skrypt powinien łączyć tokeny z każdym słownikiem (`inner_join`) i wyświetlać tabelę podsumowania oraz top 10 najczęstszych słów per słownik
- Dla słownika AFINN skrypt oblicza średni sentyment per gatunek i generuje wykres porównawczy gatunków oraz wykres słów o silnych emocjach (wartości ± 3 i ± 4)
- Dla słowników Bing i Loughran skrypt generuje wykresy słupkowe 10 najczęstszych słów pozytywnych i negatywnych
- Dla słownika NRC skrypt agreguje wiele sentymentów jednego słowa w jeden wiersz
- Skrypt powinien wyświetlać podsumowanie dotyczące sentymentu dla każdego ze słowników

4. Wymagania нефunkcjonalne

4.1. Wydajność

- Analiza zbioru danych z pliku `PoemDataset.csv` powinna zakończyć się w czasie do kilku minut
- Chmury słów i wykresy powinny być generowane bez nadmiernego obciążenia pamięci

4.2. Bezpieczeństwo danych

- Skrypt nie powinien modyfikować oryginalnego pliku wejściowego `PoemDataset.csv`
- Skrypt nie powinien modyfikować plików słowników (`afinn.csv`, `bing.csv`, `nrc.csv`, `loughran.csv`)

- Słownik do stem completion powinien być przechowywany jako zmienna globalna w sesji R

4.3. Niezawodność

- Skrypt powinien poprawnie obsługiwać brakujące wartości w zbiorze danych
- Stem completion powinno zwracać oryginalny rdzeń, jeśli nie zostanie znalezione dopasowanie
- Skrypt powinien zachować spójność między gatunkami literackimi a analizowanymi podzbiorami

4.4. Użyteczność

- Wykresy powinny być czytelne i zawierać odpowiednie etykiety osi, tytuły i napisy
- Skrypt powinien umożliwiać wykonanie wizualizacji z użyciem ggplot2 (z motywem theme_gdocs), natomiast chmury słów powinny stosować kolorystykę RColorBrewer (paleta "Dark2") dla lepszej czytelności

4.5. Kompatybilność

- Skrypt powinien być kompatybilny z językiem R w wersji 4.0 lub nowszej
- Skrypt powinien korzystać z bibliotek: tm, tidytext, tidyverse, stringr, wordcloud, RColorBrewer, ggplot2, SnowballC, ggthemes, readr

5. Interfejsy użytkownika

5.1. Wejście

- Plik PoemDataset.csv zawierający co najmniej dwie kolumny: Genre (gatunek literacki) oraz Poem (tekst utworu)
- Pliki słowników sentymentu w formacie CSV: afinn.csv, Bing.csv, nrc.csv, loughran.csv

5.2. Wyjście

- Tabele z 10 najczęściej występującymi słowami dla każdego gatunku (wyświetlane w konsoli i raporcie)
- Chmury słów dla każdego gatunku literackiego
- Podsumowania liczbowe sentymentu dla każdego słownika
- Wykresy słupkowe sentymentu: dla każdego słownika osobno oraz porównanie gatunków (AFINN)

6. Wymagania dotyczące danych

- Skrypt zakłada, że dane tekstowe są w języku angielskim
- Kolumna Genre musi zawierać niepuste etykiety gatunków literackich
- Kolumna Poem musi zawierać tekst literacki – skrypt filtruje wiersze z brakującą kolumną Poem
- Plik CSV powinien być zapisany z kodowaniem kompatybilnym z UTF-8
- Pliki słowników CSV powinny zawierać kolumny zgodne z formatem wymaganym przez polecenia tidytext (word, value/sentiment)

- Skrypt nie obsługuje analizy sentymentu dla języków innych niż angielski

7. Słownictwo dokumentacji

- **Token:** Pojedynczy element tekstu (słowo) po tokenizacji
- **Stopwords:** Słowa o niskiej wartości semantycznej, usuwane przed analizą (np. "the", "and", "is")
- **Stemming:** Proces sprowadzania słów do ich rdzenia (np. "running" → "run")
- **Stem completion:** Odwrócenie stemmingu – przywrócenie rdzennym formom najczęstszej pełnej formy słowa
- **Sentiment:** Emocjonalne nacechowanie tekstu (np. pozytywne, negatywne, neutralne)
- **AFINN:** Słownik sentymentu przypisujący słowom wartości liczbowe od -5 (bardzo negatywny) do +5 (bardzo pozytywny)
- **Bing:** Słownik binarnie klasyfikujący słowa jako pozytywne lub negatywne
- **NRC:** Słownik przypisujący słowom kategorii emocji (radość, strach, zaufanie, itp.) oraz pozytywne/negatywne
- **Loughran:** Słownik sentymentu wywodzący się z analizy finansowej, pozwala na wyodrębnienie specyficznych wyrażników w tekście, takich jak: uncertainty, constraining, litigious, czy superfluous.
- **Chmura słów:** Wizualizacja częstości słów, w której rozmiar słowa odpowiada jego częstości w tekście
- **Reproducible Research:** Podejście zapewniające pełną odtwarzalność wyników przez dostarczenie kodu i danych
- **Raport HTML:** Plik wynikowy generowany przez R Markdown zawierający kod, wykresy i analizę.
- **Genre:** Gatunek literacki – kategoria tekstów w zbiorze PoemDataset.csv

8. Przypadki użycia (Use Cases)

Użytkownik:

- Dostarcza plik PoemDataset.csv oraz pliki słowników do katalogu roboczego
- Uruchamia skrypt
- Przegląda wygenerowane chmury słów i tabele częstości
- Analizuje wykresy sentymentu dla różnych słowników
- Porównuje nacechowanie emocjonalne różnych gatunków literackich

Skrypt/System:

- Wczytuje PoemDataset.csv i pobiera unikalne gatunki
- Tworzy osobne zmienne dla tekstów każdego gatunku
- Dla każdego gatunku: oczyszcza tekst, wykonuje stemming i stem completion
- Generuje chmurę słów i tabelę top 10 dla każdego gatunku

- Tokenizuje teksty i łączy z każdym słownikiem
- Wyświetla tabele podsumowań i generuje wykresy słupkowe dla każdego słownika
- Oblicza i wizualizuje średni sentyment AFINN per gatunek

Testowe przypadki użycia:

- Test z pełnym plikiem PoemDataset.csv zawierającym kilka gatunków i tysiące wierszy
- Test poprawności oczyszczania: weryfikacja usunięcia apostrofów, cyfr i interpunkcji
- Test stemmingu i completion: sprawdzenie czy odtworzone słowa są poprawne
- Test analizy sentymentu dla tekstu o wyraźnie pozytywnym nacechowaniu
- Test analizy sentymentu dla tekstu o wyraźnie negatywnym nacechowaniu
- Test z gatunkiem zawierającym bardzo mało słów (graniczny przypadek)

9. Scenariusze użytkownika (User Stories)

Scenariusz 1: Analiza różnic w gatunkach

Jako: Badacz literatury

Chcę: Otrzymać zestawienie słów, które najczęściej występują w wierszach z różnych gatunków, oraz ich ogólnego sentymentu.

Aby: Potwierdzić swoją tezę o powtarzających się motywach językowych w konkretnych typach utworów literackich.

Kryteria akceptacji:

- Użytkownik może dostarczyć plik PoemDataset.csv z wierszami przypisanymi do gatunków
- Skrypt poprawnie oczyszcza tekst (w tym przeprowadza stemming i usuwa stopwords).
- Skrypt poprawnie dzieli wiersze na grupy według gatunku
- Dla każdego gatunku generowana jest chmura słów pokazująca najczęstsze terminy
- Tabela top 10 słów jest wyświetlana dla każdego gatunku
- Skrypt oblicza i wizualizuje na wykresie średni wskaźnik sentymentu (używając słownika AFINN) dla każdej z kategorii.

Scenariusz 2: Weryfikacja wydźwięku

Jako: Edukator i nauczyciel.

Chcę: Przeanalizować wydźwięk emocjonalny konkretnej bazy wierszy.

Aby: Wybrać odpowiednie, pozytywnie nacechowane teksty, przeznaczone do materiałów dydaktycznych dla najmłodszych.

Kryteria akceptacji:

- Skrypt poprawnie tokenizuje teksty i usuwa stopwords przed analizą sentymentu

- Skrypt filtruje, zlicza i agreguje słowa o dominującym pozytywnym i negatywnym sentymencie.
- Skrypt generuje tabele podsumowujące (top 10) oraz czytelne wykresy słupkowe z podziałem na emocje.
- Użytkownik na podstawie wygenerowanych wizualizacji może zidentyfikować grupy słów o dominującym sentymencie pozytywnym.